Assignment 3. NLP

(загрузить в moodle и защитить до 31.10.2025)
Если Assignment загружен и защищён с опозданием,
то -20% от каждого задания,
т.е. если все выполнено, макс оценка 80 баллов.

Задание 1. (25 б) Разработка и тестирование определения тональности текста

Постановка задачи

Ввод: предложение (или отзыв) для оценки эмоциональной окраски.
Вывод: тональность предложения по шкале: негативный, нейтральный, позитивный.

Реализуйте два подхода:
1. Лексиконный — на основе словаря тонально окрашенных слов (например, SentiWords).
2. Машинное обучение — классификатор, обученный на размеченном датасете (например, IMDb, Amazon reviews).

Ход выполнения работы

Шаг 1. Загрузка и подготовка данных
- Выберите датасет отзывов (IMDb, отзывы о продуктах Amazon, или аналог).
- Разделите данные на обучающую, валидационную и тестовую выборки.

Шаг 2. Предобработка текстов
- Токенизация (разделение на слова).
- Приведение к нижнему регистру.
- Удаление стоп-слов.
- Лемматизация (нормализация слов).

Шаг 3. Преобразование текстов в векторы
- Bag-of-Words или TF-IDF.
- Для лексиконного метода — вычислите «тональный балл» по словарю.

Шаг 4. Обучение модели
- Обучите классификатор (логистическая регрессия или Naive Bayes). - Для лексиконного подхода подберите пороги для классификации на 3 класса.

Шаг 5. Оценка качества
- Постройте confusion matrix.
- Рассчитайте метрики: accuracy, F1-score.

Шаг 6. Анализ ошибок
- Найдите примеры неверно классифицированных предложений. - Проанализируйте причины ошибок: сарказм, многозначные слова, ошибки предобработки.

- Предложите улучшения (например, расширение словаря, использование контекстных моделей, обработка отрицаний).

Шаг 7. Визуализация

- Постройте word cloud для позитивных и негативных отзывов.
- Выведите топ-важные слова (по весам модели).

Задание 2. (25 б) Разработка и тестирование метода автоматического реферирования

Постановка задачи

Вход: 3 текстовых файла (прикреплены к заданию).

Выход:

1. **Extractive summarization**:
   - Выбрать по 3 ключевых предложения из каждого документа.
   - Сформировать единый сводный список из 6 предложений для всех документов.
   - Сделать краткий вывод по результатам.
2. **Abstractive summarization (усложнённый вариант):**
   - По 5 документам составить краткий реферат, который должен быть:
     - короче исходных документов,
     - грамматически связным и корректным,
     - содержать самую важную информацию.

Ход выполнения работы

Шаг 1. Загрузка данных

- Использовать предоставленные 3 (или 5) текстовых документа.
- Считать их в программу (например, open() или pandas).

Шаг 2. Предобработка текстов

- Токенизация предложений.
- Очистка текста (удаление спецсимволов, приведение к нижнему регистру).
- Опционально: удаление стоп-слов, лемматизация.

Шаг 3. Extractive summarization

- Рассчитать «важность» предложений (например, по TF-IDF или TextRank).
- Извлечь 3 предложения на документ.
- Сформировать итоговый список из 6 предложений (по максимальному весу среди всех документов).

Шаг 4. Abstractive summarization (усложнённый вариант)

- Использовать библиотеку HuggingFace (transformers) и предобученные модели (например, t5-small, bart-large-cnn).
- Сгенерировать связный реферат по набору документов.

Шаг 5. Оценка качества

- Оценить extractive и abstractive результаты.
- Оценить: полноту, связность, корректность.

Задание 3. (25 б) Разработка и тестирование методов выделения упоминаний в текстах песен

Задачи:

1. Собрать корпус текстов песен по минимум 4 жанрам, не менее 10 песен на жанр.
2. Выполнить предобработку: удалить стоп-слова, привести слова к единому регистру, выполнить лемматизацию.
3. Определить:
    - 10 наиболее часто встречающихся слов для каждого жанра;
    - слова из определённой категории (например: время суток, сезоны года, части тела и др.) для каждого жанра;
    - редкие слова — слова, встречающиеся в каждом жанре не более 3 раз.

Источники данных

Тексты песен можно взять из открытых онлайн-источников:
- Genius Lyrics (https://genius.com/) — англоязычные тексты песен.
- AZLyrics (https://www.azlyrics.com/) — англоязычные тексты по жанрам.
- LyricFind (https://www.lyricfind.com/) — лицензированные тексты.
- AmDm.ru (https://amdm.ru/akkordi/) — русскоязычные тексты песен.
- **Kaggle datasets:**
    - Lyrics Dataset — собранные тексты по 6 жанрам.
    - MetroLyrics dataset — корпус песен по жанрам.

(рекомендуется использовать Kaggle, так как данные уже структурированы и размечены по жанрам).

Ход выполнения работы

Шаг 1. Сбор данных
- Скачать датасет с Kaggle (например, *Scrapped Lyrics from 6 Genres*).
- Отобрать 4 жанра, по 10 песен каждый.

Шаг 2. Предобработка
- Привести тексты к нижнему регистру.
- Удалить знаки препинания.
- Удалить стоп-слова (NLTK, spaCy).
- Лемматизация (pymorphy2 для русского, spaCy для английского).

Шаг 3. Частотный анализ
- Подсчитать частоты слов в каждом жанре.
- Построить топ-10 слов для каждого жанра.

Шаг 4. Анализ по категориям
- Составить словари категорий, НАПРИМЕР:
    - время суток: утро, день, вечер, ночь;
    - сезоны года: зима, весна, лето, осень;

- части тела: глаза, сердце, руки и т. п.

• Подсчитать частоту слов из этих категорий в каждом жанре.

Шаг 5. Поиск редких слов

• Определить слова, встречающиеся во всех жанрах не более 3 раз.

Задание 4. Определение языка текста (25 баллов)

Постановка задачи

Определение языка (language identification) - это задача автоматического определения того, на каком языке написан заданный текст. Это первый шаг во многих реальных системах: машинном переводе, поисковых системах, фильтрации спама и многоязычных чат-ботах. Задача усложняется, когда языки близкородственные (например, испанский и португальский), когда текст очень короткий или содержит шум: опечатки, имена собственные.

В этом задании необходимо построить и оценить систему определения языка, а также изучить, как предобработка, признаки и выбор модели влияют на качество.

Вход: короткий текст (одно слово, одно предложение или 1-2 предложения), например: *"Бүгін ауа райы өте жақсы."*

Выход: предсказанная метка языка (например, казахский, русский, английский, французский, испанский, португальский), по желанию с оценкой уверенности модели.

Ход выполнения работы

Шаг 1. Сбор данных

• Используйте готовый датасет (Tatoeba или WiLI-2018). Выберите 6-8 языков, среди которых есть хотя бы одна пара похожих языков (например, казахский и русский или испанский и португальский).

• Возьмите не менее 500 предложений на каждый язык.

• Разделите данные на train/test (80/20) и убедитесь, что между выборками нет повторяющихся предложений.

Шаг 2. Предобработка (с небольшим экспериментом)

• Сравните две версии: (а) приведение к нижнему регистру и удаление цифр и специальных символов, (б) минимальная очистка.

• Объясните, какой вариант работает лучше и почему. Подсказка:

специальные буквы ә, қ, ғ, ң, ө, ү являются сильными признаками языка.

Шаг 3. Признаки

• Символьные n-граммы (1-3) с TF-IDF (частоты букв, биграмм и триграмм).

• Сравните с TF-IDF на уровне слов.

Шаг 4. Обучение модели

- Обучите наивный байесовский классификатор (Naive Bayes) и логистическую регрессию.
- Сравните с одной предобученной моделью (fastText `lid.176`).

Шаг 5. Оценка качества

- Рассчитайте accuracy и macro F1 на тестовой выборке.
- Постройте матрицу ошибок (confusion matrix).
- Объясните 2-3 наиболее частые ошибки (какие языки путаются и почему).
- Постройте график зависимости accuracy от длины текста (например, 1-3 слова, одно предложение, 2 и более предложений).

Контрольные вопросы

1. В чём разница между extractive и abstractive summarization? 2. Почему методы на основе TF-IDF/GraphRank выбирают именно предложения, а не слова?
3. Какие сложности возникают при генерации абстрактивных рефератов?
4. Что такое ROUGE-метрики и как их применяют для оценки качества?
5. Почему грамматическая корректность особенно важна для абстрактивных моделей?
6. Чем отличаются лексиконный и ML-подходы к анализу тональности?
7. Зачем нужна лемматизация?
8. Что показывает матрица ошибок (confusion matrix)?
9. Почему accuracy иногда вводит в заблуждение?
10. Какие факторы могут мешать корректному определению тональности?
11. В чём разница между нормализацией и стандартизацией данных? 12. В чём преимущество TF-IDF перед простым подсчётом частот слов?
13. Почему абстрактивные модели часто совершают грамматические ошибки?
14. Чем ROC-кривая отличается от Precision-Recall кривой?
15. Что представляет собой метод Bag-of-Words и как он работает?